

Optimización de Costos del Sistema

Objetivo

Seleccionar el modelo de IA más adecuado para cada tarea, equilibrando calidad de respuesta, velocidad de procesamiento y costo operativo.

Tarea	Modelo seleccionado	Justificación
Clasificación de reclamos	GPT-4o Mini	Excelente relación costo/rendimiento para texto corto.
Análisis de sentimiento	GPT-4o Mini	Precisión suficiente sin utilizar modelos de mayor costo.
Priorización del caso	GPT-4o Mini	Requiere razonamiento moderado y respuestas estructuradas.
Selección de política	GPT-4o Mini	El contexto es reducido y las reglas están definidas.
Generación de respuesta	GPT-4o Mini	Produce respuestas naturales con bajo consumo de tokens.
Procesamiento masivo (futuro)	Batch API	Permitiría reducir costos en ejecuciones por lotes.
Lectura de documentos extensos (futuro)	Claude	Mayor ventana de contexto para documentos complejos.

Estrategias de optimización implementadas

- Uso de GPT-4o Mini como modelo principal.
- Prompt estructurado para minimizar respuestas innecesarias.
- Límite de tokens configurado en OpenAI.
- Envío únicamente de los datos necesarios al modelo.
- Uso de temperatura baja para obtener respuestas consistentes.

Conclusión

La elección de GPT-4o Mini permite mantener un equilibrio entre precisión,

velocidad y costo, siendo adecuado para un sistema de atención de reclamos que procesa mensajes relativamente breves.